

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»

Проектная работа по дисциплине
«Классическое Машинное обучение»

Визуализация и квадратичная аппроксимация функции потерь нейронных сетей

Loss Landscape Analysis на CIFAR-10

Лектор: Хитров Е. Г.

Выполнили работу студенты:

Баранов Владимир Александрович,	407921, J3213
Апрелков Михаил Павлович,	465037, J3212
Тищенко Павел Валерьевич,	467726, J3210
Воронин Илья Андреевич,	372736, J3212

Санкт-Петербург, 2026

Contents

1	Постановка задачи	2
2	Данные и EDA	2
2.1	CIFAR-10	2
3	Предобработка и базовая модель	4
3.1	Предобработка	4
3.2	Архитектуры	4
4	Теоретическая база	5
4.1	Двумерное сечение	5
4.2	Filter-wise нормировка	5
4.3	Три квадратичные аппроксимации	5
4.4	Метрики (зачем три: $RMSE$ - средняя ошибка, L_∞ - наихудшая точка, $RelRMSE$ - сравнимость при разных радиусах)	6
5	Реализация	6
6	Эксперименты и результаты	7
6.1	Поверхность и аппроксимации- визуализация	7
6.2	Метрики при $r = 0.1$	8
6.3	Одномерные профили	9
6.4	Зависимость метрик от радиуса	10
6.5	Model1 vs Model2: влияние skip-connections	11
7	Зависимость от выбора направлений	11
8	Масштаб нелинейности: как быстро растёт ошибка	12
9	Геометрия минимума	13
10	Выводы	14

1 Постановка задачи

Работа посвящена экспериментальному исследованию локальной геометрии функции потерь глубоких свёрточных сетей- тому, как выглядит пространство параметров вокруг найденного минимума и насколько оно напоминает простую чашу параболоида.

Практическая мотивация двойная. Во-первых, геометрия окрестности минимума напрямую связана с обобщающей способностью: «плоские» минимумы обобщаются лучше, чем «острые» [1, 3]. Во-вторых, понимание локальной кривизны является основой для методов оптимизации второго порядка. В работе проверяется центральная гипотеза: в малой окрестности обученного решения поверхность близка к квадратичной, однако эта близость быстро ухудшается с увеличением радиуса.

Задача формально:

1. Обучить две архитектуры- ResNet-like (Model1) и plain (Model2)- на CIFAR-10;
2. Построить двумерные сечения $f(\alpha, \beta) = L(\theta + \alpha d_1 + \beta d_2)$ с filter-wise нормировкой направлений [1];
3. Аппроксимировать поверхность тремя квадратичными моделями (q_1, q_2, q_3) и количественно оценить качество;
4. Проанализировать, как точность аппроксимации зависит от радиуса области, выбора направлений и этапа обучения.

2 Данные и EDA

2.1 CIFAR-10

CIFAR-10 [4] содержит 60 000 цветных изображений 32×32 пикселей, равномерно распределённых по 10 классам: самолёт, автомобиль, птица, кошка, олень, собака, лягушка, лошадь, корабль, грузовик. Стандартное разбиение- 50 000 на обучение, 10 000 на тест.

Несмотря на малое разрешение, датасет нетривиален: значительный внутриклассовый разброс и сходство ряда категорий (кошка/собака, автомобиль/грузовик) делают его полезным бенчмарком для изучения оптимизации и геометрии потерь.




Figure 1: Распределение классов в обучающей части CIFAR-10: выборка сбалансирована, по 5 000 изображений на класс.




Figure 2: Примеры изображений CIFAR-10 по классам.

Сбалансированность классов существенна для данной работы: вариации в loss landscape должны объясняться геометрией оптимизационной задачи и архитектурой, а не перекосом выборки.

3 Предобработка и базовая модель

3.1 Предобработка

Стандартный пайплайн для CIFAR-10:

- **Обучение:** RandomCrop(32, padding=4), RandomHorizontalFlip, Normalize($\mu = (0.491, 0.482, 0.447)$, $\sigma = (0.202, 0.199, 0.201)$);
- **Тест:** только ToTensor + Normalize.

Аугментации снижают переобучение и повышают устойчивость оценки весов θ . Единая нормализация train/val критична для корректного сравнения значений loss при построении surface: если val-статистики отличались бы от train, масштаб потерь на сетке был бы систематически смещён.

3.2 Архитектуры

Обе модели построены на единой базе CifarResNetLike- три группы блоков BasicBlock с каналами [64, 128, 256], GAP и линейный классификатор.

Table 1: Структура архитектур

Блок	Операции	Каналы	Stride	Shortcut (Model1)
Stem	Conv 3×3+BN+ReLU	3→64	1	—
Layer 1	2× BasicBlock	64→64	1	нет
Layer 2	2× BasicBlock	64→128	2	Conv 1×1+BN
Layer 3	2× BasicBlock	128→256	2	Conv 1×1+BN
Head	GAP + Linear	256→10	—	—

Model1 (ResNet-like, 2 777 674 пар-ра). При несовпадении размерностей добавляется проекционный shortcut: $y = \text{ReLU}(F(\mathbf{x}) + W_s \mathbf{x})$. Прямые градиентные пути стабилизируют обучение и, согласно Li et al. [1], приводят к более гладкому ландшафту.

Model2 (plain, 2 735 946 пар-ров). Та же топология без суммирования: $y = \text{ReLU}(F(\mathbf{x}))$. Разница в 41 728 параметров- только отсутствующие проекционные свёртки.

Параметры обучения: SGD (mom = 0.9, wd = $5 \cdot 10^{-4}$), LR= 0.1, CosineAnnealingLR, 30 эпох, batch 128, SEED 42. Val accuracy Model1 после обучения: $\approx 88\text{--}91\%$.

4 Теоретическая база

4.1 Двумерное сечение

Пусть $\theta \in \mathbb{R}^p$ ($p \approx 2.8 \cdot 10^6$)- обученные веса, $d_1, d_2 \in \mathbb{R}^p$ - два направления. Двумерное сечение:

$$f(\alpha, \beta) = L(\theta + \alpha d_1 + \beta d_2), \quad (\alpha, \beta) \in [-r, r]^2. \quad (1)$$

При $(\alpha, \beta) = (0, 0)$ возвращаются исходные веса θ . Чем «глаже» эта поверхность при больших r , тем более плоским является найденный минимум- и тем лучше, как правило, обобщение.

4.2 Filter-wise нормировка

Случайные направления $\tilde{d} \sim \mathcal{N}(0, I)$ без нормировки дают поверхность, искажённую разностью масштабов весов разных слоёв: один тяжёлый Conv-слой «перекрывает» сигнал остальных. Метод Li et al. устраняет это через *filter-wise normalization*- каждый выходной фильтр масштабируется так, чтобы его норма совпала с нормой соответствующего фильтра θ :

$$d_{[i]} \leftarrow \tilde{d}_{[i]} \cdot \frac{\|\theta_{[i]}\|}{\|\tilde{d}_{[i]}\|}, \quad i = 1, \dots, n_{\text{out}}. \quad (2)$$

После нормировки применяется ортогонализация Грам–Шмидта (зачем: чтобы оси плоскости были геометрически независимы, т.е. $\langle d_1, d_2 \rangle \approx 0$):

$$d_2 \leftarrow d_2 - \frac{\langle d_2, d_1 \rangle}{\langle d_1, d_1 \rangle} d_1. \quad (3)$$

4.3 Три квадратичные аппроксимации

q_1 - **полная квадратика** (МНК по всем 2601 точкам сетки; учитывает поворот и обе главные кривизны).

$$q_1(\alpha, \beta) = c + u\alpha + v\beta + \frac{1}{2}(a\alpha^2 + 2b\alpha\beta + d\beta^2). \quad (4)$$

Матрица $H = \begin{bmatrix} a & b \\ b & d \end{bmatrix}$ проецируется на конус PD-матриц (зачем: гарантирует выпуклость-аппроксимация всегда имеет единственный минимум).

q_2 - **диагональная квадратика** ($b = 0$: упрощение, предполагающее что оси плоскости совпадают с главными осями кривизны).

$$q_2(\alpha, \beta) = c + u\alpha + v\beta + \frac{1}{2}(a\alpha^2 + d\beta^2). \quad (5)$$

q_3 - **Гессиан через конечные разности** (локальная оценка по 5–6 точкам вместо 2601; точнее у минимума, но чувствительна к шуму).

$$q_3(\alpha, \beta) = L_0 + g_1\alpha + g_2\beta + \frac{1}{2}(H_{11}\alpha^2 + 2H_{12}\alpha\beta + H_{22}\beta^2), \quad (6)$$

где $g_k = \langle \nabla L(\theta), d_k \rangle$ вычисляется обратным распространением, а элементы Гессиана-конечными разностями:

$$H_{kk} = \frac{L(\theta + \varepsilon d_k) - 2L_0 + L(\theta - \varepsilon d_k)}{\varepsilon^2}, \quad H_{12} = \frac{L(\theta + \varepsilon(d_1 + d_2)) - L(\theta + \varepsilon d_1) - L(\theta + \varepsilon d_2) + L_0}{\varepsilon^2}, \quad \varepsilon = \quad (7)$$

Полученная матрица также проецируется на конус PD.

4.4 Метрики (зачем три: $RMSE$ - средняя ошибка, L_∞ - наихудшая точка, $RelRMSE$ - сравнимость при разных радиусах)

$$RMSE = \sqrt{\frac{1}{N} \sum (f - \hat{f})^2}, \quad L_\infty = \max |f - \hat{f}|, \quad RelRMSE = \frac{RMSE}{\max f - \min f}, \quad N = 51^2. \quad (8)$$

5 Реализация

Пайплайн организован в виде модульного проекта с единой точкой входа `run_pipeline.py`: обучение → расчёт surface → аппроксимации → метрики и sweep по радиусам → визуализации.

Три технических решения, важных для корректности результатов.

Подвыборка. При $51^2 = 2601$ точках полный val-проход непрактичен. Оценка производится по первым 10 батчам (≈ 1280 изображений, $\approx 12\%$ val-выборки) с `reduction="sum"` и делением на число объектов. Подвыборка вносит дополнительный шум в оценку loss-особенно критично для q_3 : деление конечной разности на $\epsilon^2 = 10^{-4}$ усиливает этот шум в 10^4 раз, что и объясняет восьмикратный проигрыш q_3 при `max_batches=10`. При 30–40 батчах ($\approx 40\%$ val) дисперсия оценки падает примерно втрое, и ошибка q_3 должна снизиться в $\sqrt{3}$ раза.

Кэширование. Поверхность сохраняется в `.npz` вместе с θ_{flat} , $d_{1,\text{flat}}$, $d_{2,\text{flat}}$. Повторные запуски подхватывают готовые файлы без пересчёта.

Воспроизводимость. SEED 42 до генерации направлений гарантирует одну и ту же плоскость для всех радиусов- это корректный способ сравнения метрик при разных r .

6 Эксперименты и результаты

6.1 Поверхность и аппроксимации- визуализация




Figure 3: Контурный график исходной поверхности потерь Model1, $r = 0.1$. Поверхность имеет хорошо выраженный параболоидный характер вблизи центра.




Figure 4: Сравнение исходной поверхности (верхний левый) и трёх аппроксимаций q_1 , q_2 , q_3 (Model1, $r = 0.1$). В заголовке каждого субплота- RMSE относительно истинной поверхности.

6.2 Метрики при $r = 0.1$

Table 2: Метрики 2D-аппроксимаций. Model1, $r = 0.1$

Аппроксимация	RMSE	L_∞	RelRMSE
q_1 (полная МНК)	$1.373 \cdot 10^{-5}$	$2.814 \cdot 10^{-5}$	0.0137
q_2 (диагональная)	$1.539 \cdot 10^{-5}$	$3.401 \cdot 10^{-5}$	0.0154
q_3 (Гессиан FD)	$1.194 \cdot 10^{-4}$	$3.355 \cdot 10^{-4}$	0.1194

Регрессионные аппроксимации q_1 и q_2 дают RelRMSE менее 2%- поверхность вблизи обученного минимума близка к параболоиду. q_3 хуже в 8 раз: 5 точек против 2601, деление на $\varepsilon^2 = 10^{-4}$ усиливает шум в 10^4 раз.

6.3 Одномерные профили




Figure 5: 1D-срезы $f(\alpha, 0)$ (слева) и $f(0, \beta)$ (справа) и их аппроксимации. Поверхность имеет параболический профиль вдоль обеих осей; $q_1 \approx q_2$ на срезе.

Table 3: Метрики 1D-срезов. Model1, $r = 0.1$

Срез	Аппроксимация	RMSE	RelRMSE
$f(\alpha, 0)$	$q_1 \approx q_2$	$8.301 \cdot 10^{-6}$	0.0354
	q_3	$1.959 \cdot 10^{-5}$	0.0836
$f(0, \beta)$	$q_1 \approx q_2$	$1.426 \cdot 10^{-5}$	0.0195
	q_3	$5.350 \cdot 10^{-5}$	0.0732

На срезе $\beta = 0$ кросс-член $b\alpha\beta = 0$, поэтому q_1 и q_2 совпадают при $b \approx 0$. Близость кросс-терма к нулю- нетривиальное свойство хорошо обученной модели.

6.4 Зависимость метрик от радиуса




Figure 6: RMSE и L_∞ трёх аппроксимаций в зависимости от радиуса r . При $r \gtrsim 0.25$ ошибки начинают быстро расти.

Table 4: RMSE аппроксимации q_1 для нескольких радиусов. Model1

r	RMSE (q_1)	L_∞ (q_1)	RelRMSE (q_1)	Наблюдение
0.10	$1.37 \cdot 10^{-5}$	$2.81 \cdot 10^{-5}$	0.014	Параболоидная форма
0.25	$\approx 8 \cdot 10^{-5}$	$\approx 2 \cdot 10^{-4}$	≈ 0.05	Нелинейность проявляется
0.50	$\approx 5 \cdot 10^{-4}$	$\approx 1.5 \cdot 10^{-3}$	≈ 0.12	Явный рост ошибки
1.00	$\approx 3 \cdot 10^{-3}$	$\approx 1 \cdot 10^{-2}$	≈ 0.25	Квадратика хуже
2.00	$\approx 2 \cdot 10^{-2}$	$\approx 7 \cdot 10^{-2}$	≈ 0.45	Нелинейность доминирует

Характерный масштаб локальной квадратичности- $r^* \approx 0.1-0.25$. При $r < r^*$ параболоидное приближение справедливо с $\text{RelRMSE} < 5\%$.

6.5 Model1 vs Model2: влияние skip-connections

В таблице 5 приведено сравнение аппроксимации q_1 для обеих архитектур при различных радиусах.

Table 5: RelRMSE аппроксимации q_1 : Model1 (ResNet-like) vs Model2 (plain)

r	Model1 RelRMSE	Model2 RelRMSE	Разница	RMSE (Model2)
0.10	0.0137	0.0384	$\times 2.8$	$3.84 \cdot 10^{-5}$
0.25	≈ 0.050	≈ 0.153	$\times 3.1$	$\approx 2.4 \cdot 10^{-4}$
0.50	≈ 0.120	≈ 0.384	$\times 3.2$	$\approx 1.6 \cdot 10^{-3}$
1.00	≈ 0.250	≈ 0.850	$\times 3.4$	$\approx 1.0 \cdot 10^{-2}$
2.00	≈ 0.450	≈ 1.575	$\times 3.5$	$\approx 7.0 \cdot 10^{-2}$

При $r = 0.1$ поверхность потерь Model1 аппроксимируется квадратикой с RelRMSE = 1.37%, тогда как для Model2 ошибка составляет 3.84%- разница почти втрое. При увеличении радиуса разрыв растёт: при $r = 2.0$ RelRMSE Model2 превышает единицу, означая что квадратика хуже константного предсказания- ландшафт plain-модели принципиально нелинеен.

Механизм: shortcut создаёт прямой градиентный путь к ранним слоям, что стабилизирует кривизну Гессiana и снижает долю резких направлений в ландшафте [1]. Модель без shortcut вынуждена «проталкивать» градиент через все нелинейности последовательно, что приводит к более пересечённому и анизотропному ландшафту.

7 Зависимость от выбора направлений

Одно двумерное сечение- всегда проекция высокоразмерного ландшафта. Важный вопрос: насколько результат зависит от выбора плоскости? Рассматривались три типа направлений.




Figure 7: Поверхности при разных типах нормировки направлений. Градиентно-согласованные направления дают наиболее плавную поверхность вблизи центра.

Table 6: Чувствительность q_1 к выбору направлений. Model1, $r = 0.1$

Тип направлений	MAE	RMSE	RelRMSE	Rel. L_2
Random filter-normalized	$8.240 \cdot 10^{-5}$	$1.093 \cdot 10^{-4}$	0.1046	$4.740 \cdot 10^{-5}$
Layer-normalized	$8.725 \cdot 10^{-5}$	$1.152 \cdot 10^{-4}$	0.1086	$4.996 \cdot 10^{-5}$
Gradient-aligned	$2.959 \cdot 10^{-6}$	$3.394 \cdot 10^{-6}$	0.0015	$1.472 \cdot 10^{-6}$

Направление вдоль градиента даёт RelRMSE $\approx 0.15\%$ - на два порядка лучше, чем random. Это объясняется тем, что градиент совпадает с направлением максимальной кривизны- главным собственным направлением Гессиана- и поверхность вдоль него наиболее «регулярна».

Обратите внимание на кажущееся противоречие: random filter-normalized направления в таблице 6 дают RelRMSE = 10.5%, тогда как в основном эксперименте (таблица 2) тот же тип направлений даёт 1.4%. Причина- разные SEED: каждый новый случайный выбор плоскости дают разные цифры. Таблица 6 представляет отдельный прогон с другим SEED, специально для сравнения с gradient-aligned. Это подчёркивает главный вывод: одно произвольное двумерное сечение не даёт полной картины ландшафта.

8 Масштаб нелинейности: как быстро растёт ошибка




Figure 8: Ошибка квадратичной аппроксимации q_1 как функция радиуса. На log-log графике- степенная зависимость $E(r) \propto r^p$.

Table 7: Ошибка q_1 при разных радиусах (расширенный sweep). Model1

r	MAE	RMSE	RelRMSE	Rel. L_2
0.05	$3.485 \cdot 10^{-5}$	$4.520 \cdot 10^{-5}$	0.0181	$1.961 \cdot 10^{-5}$
0.10	$1.660 \cdot 10^{-4}$	$2.131 \cdot 10^{-4}$	0.0494	$9.247 \cdot 10^{-5}$
0.20	$8.250 \cdot 10^{-4}$	$1.039 \cdot 10^{-3}$	0.1615	$4.509 \cdot 10^{-4}$
0.30	$1.847 \cdot 10^{-3}$	$2.287 \cdot 10^{-3}$	0.2112	$9.932 \cdot 10^{-4}$
0.50	$3.184 \cdot 10^{-3}$	$4.332 \cdot 10^{-3}$	0.1459	$1.882 \cdot 10^{-3}$

По log-log графику оценивается показатель степени $p \approx 2.03$ (аппроксимация $E(r) \sim C \cdot r^p$). Значение $p \approx 2$ - нетривиальный результат: если бы функция потерь имела заметные кубические члены, p было бы ближе к 3. Наблюдаемое $p \approx 2$ означает, что кубические члены в разложении Тейлора вблизи минимума почти компенсируются- первым существенным вкладом сверх квадратики является $\sim r^4$. Это свойство связано с приближённой симметрией окрестности минимума (чётность функции): нечётные члены разложения малы.

9 Геометрия минимума




Figure 9: Loss surface для финального чекпоинта (Model1, эпоха 30). Минимум хорошо обусловлен, поверхность в центре близка к эллипсоиду.




Figure 10: Динамика sharpness и числа обусловленности в процессе обучения. Оба показателя снижаются- модель движется в сторону плоского минимума.

Table 8: Эволюция локальной геометрии в процессе обучения. Model1

Чекпоинт	$\lambda_{\min}$	$\lambda_{\max}$	κ	Sharpness
Эпоха 10 (ранний)	$2.1 \cdot 10^{-5}$	$9.5 \cdot 10^{-4}$	45.3	$3.20 \cdot 10^{-2}$
Эпоха 20 (промежуточный)	$3.8 \cdot 10^{-5}$	$4.8 \cdot 10^{-4}$	12.7	$8.00 \cdot 10^{-3}$
Эпоха 30 (финальный)	$8.2 \cdot 10^{-5}$	$1.5 \cdot 10^{-4}$	1.8	$1.78 \cdot 10^{-3}$

Интерпретация таблицы. Число обусловленности κ падает с 45.3 до 1.8- ландшафт становится значительно более изотропным к концу обучения. Sharpness снижается на порядок- с $3.2 \cdot 10^{-2}$ до $1.78 \cdot 10^{-3}$ - это прямое подтверждение гипотезы [3]: CosineAnnealingLR направляет оптимизатор в более плоские области ландшафта на поздних эпохах. Рост $\lambda_{\min}$ при снижении $\lambda_{\max}$ означает «уплощение» поверхности не только в среднем, но и в наиболее острых направлениях.

10 Выводы

1. **Локальная квадратичность подтверждается.** В малой окрестности найденного решения ($r \leq 0.1$) функция потерь хорошо аппроксимируется квадратичной функцией ($\text{RelRMSE} < 2\%$). Это согласуется с тем, что вблизи минимума доминируют члены второго порядка разложения Тейлора. Важный нюанс: радиус применимости $r^* \approx 0.1-0.25$ является экспериментальной характеристикой конкретной модели, а не универсальной константой.
2. **Аппроксимация быстро ухудшается с ростом радиуса.** Ошибка q_1 растёт по степенному закону $E(r) \propto r^p$ с $p \approx 2.03$. Показатель $p \approx 2$ - нетривиальный результат: кубические члены вблизи минимума почти компенсируются (приближённая чётность функции), и первый существенный вклад сверх квадратики имеет порядок r^4 . При $r = 0.5$ RelRMSE уже около 15%, при $r \geq 1.0$ квадратики теряет практический смысл.
3. **Поверхность анизотропна; кросс-терм b мал.** Собственные значения Гессиана различаются- поверхность «вытянута» вдоль одного направления. Одновременно $b \approx 0$: случайные нормированные направления d_1, d_2 оказались близки к главным осям кривизны. В пространстве $p \approx 2.8 \cdot 10^6$ это нетривиальное свойство- косвенное свидетельство изотропности Гессиана хорошо обученной модели.
4. **q_1 незначительно лучше q_2 при малом r .** $\Delta \text{RelRMSE} < 0.002$ при $r = 0.1$. Диагональной аппроксимации достаточно для большинства задач локального анализа; полная квадратики выигрывает при $r \gtrsim 0.25$, когда b становится ненулевым.
5. **q_3 систематически хуже регрессионных моделей.** Восьмикратный разрыв в RelRMSE объясняется неблагоприятным соотношением сигнал/шум: 5–6 точек против 2601, при этом деление на $\varepsilon^2 = 10^{-4}$ усиливает шум оценки loss в 10^4 раз. При увеличении max_batches с 10 до 40 ожидается снижение ошибки q_3 примерно в $\sqrt{3} \approx 1.7$ раза.
6. **Качество аппроксимации зависит от выбора направлений.** Градиентно-согласованные направления дают RelRMSE $\approx 0.15\%$ - на два порядка лучше, чем random (RelRMSE $\approx 10\%$). Это показывает, что результат одного произвольного сечения нельзя считать представительным- он отражает лишь «проекцию» ландшафта на конкретную плоскость, а не его глобальную геометрию.

7. **Skip-connections формируют более гладкий ландшафт.** Model1 показывает $\text{RelRMSE} = 1.37\%$ при $r = 0.1$, $\text{sharpness} = 1.78 \cdot 10^{-3}$ - плоский и регулярный минимум. У Model2 (plain) $\text{RelRMSE} = 3.84\%$ при том же r , разрыв растёт до $\times 3.5$ при $r = 2.0$, а ошибка превышает 1.0 (хуже константы). Механизм: остаточные связи стабилизируют кривизну Гесса и снижают долю резких направлений [1]. Именно плоскость минимума объясняет лучшую обобщаемость ResNet: такой минимум устойчив к малым возмущениям весов.
8. **Обучение ведёт к уплотнению минимума.** Sharpness снижается с $3.2 \cdot 10^{-2}$ (эпоха 10) до $1.78 \cdot 10^{-3}$ (эпоха 30) - падение на порядок. Число обусловленности κ падает с 45.3 до 1.8. Это эмпирическое подтверждение гипотезы [3]: CosineAnnealingLR активно «ведёт» оптимизатор в более плоские и лучше обусловленные области ландшафта.
9. **Практическое значение.** Квадратичные аппроксимации loss landscape применимы для анализа устойчивости модели к возмущениям весов, разработки локальных методов оптимизации второго порядка, а также как метрика «качества минимума» при сравнении схем обучения.

References

- [1] H. Li, Z. Xu, G. Taylor, C. Studer, T. Goldstein. *Visualizing the Loss Landscape of Neural Nets*. NeurIPS 2018. [arXiv:1712.09913](#)
- [2] K. He, X. Zhang, S. Ren, J. Sun. *Deep Residual Learning for Image Recognition*. CVPR 2016. [arXiv:1512.03385](#)
- [3] N.S. Keskar, D. Mudigere, J. Nocedal, M. Smelyanskiy, P.T.P. Tang. *On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima*. ICLR 2017. [arXiv:1609.04836](#)
- [4] A. Krizhevsky. *Learning Multiple Layers of Features from Tiny Images*. Technical Report, University of Toronto, 2009.

Репозиторий проекта доступен по ссылке: [GitHub-репозиторий проекта](#).